Vizuelno razumevanje scene kroz neurosimboličko rezonovanje

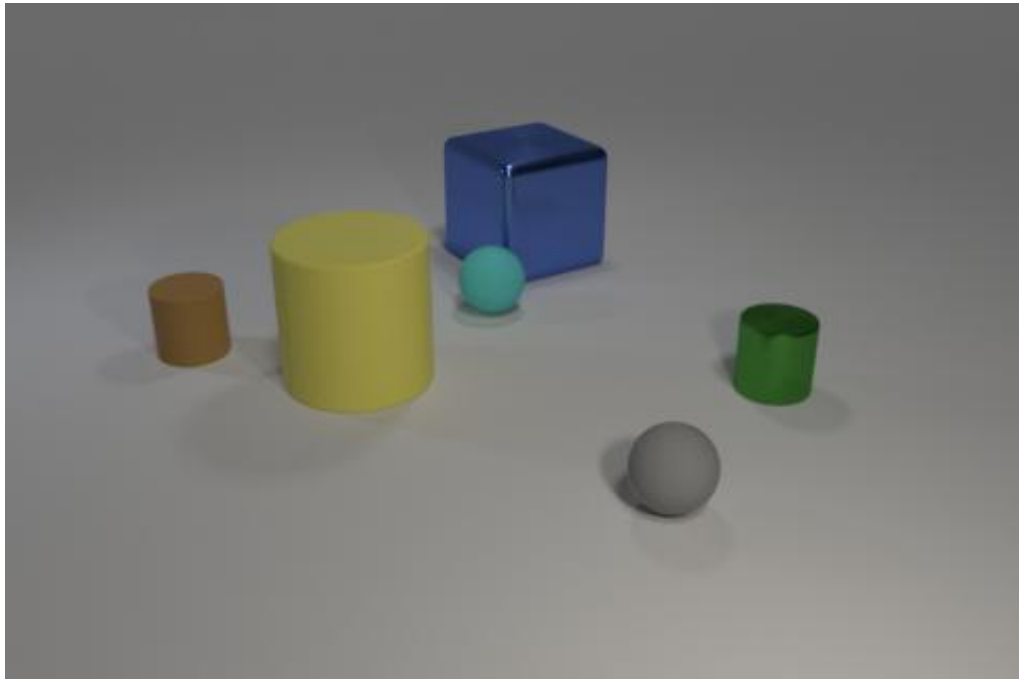
Diplomski rad

Bogdan Đukić, RA98/2021

Mentor: dr. Milan Segedinac

Univerzitet u Novom Sadu, Fakultet tehničkih nauka

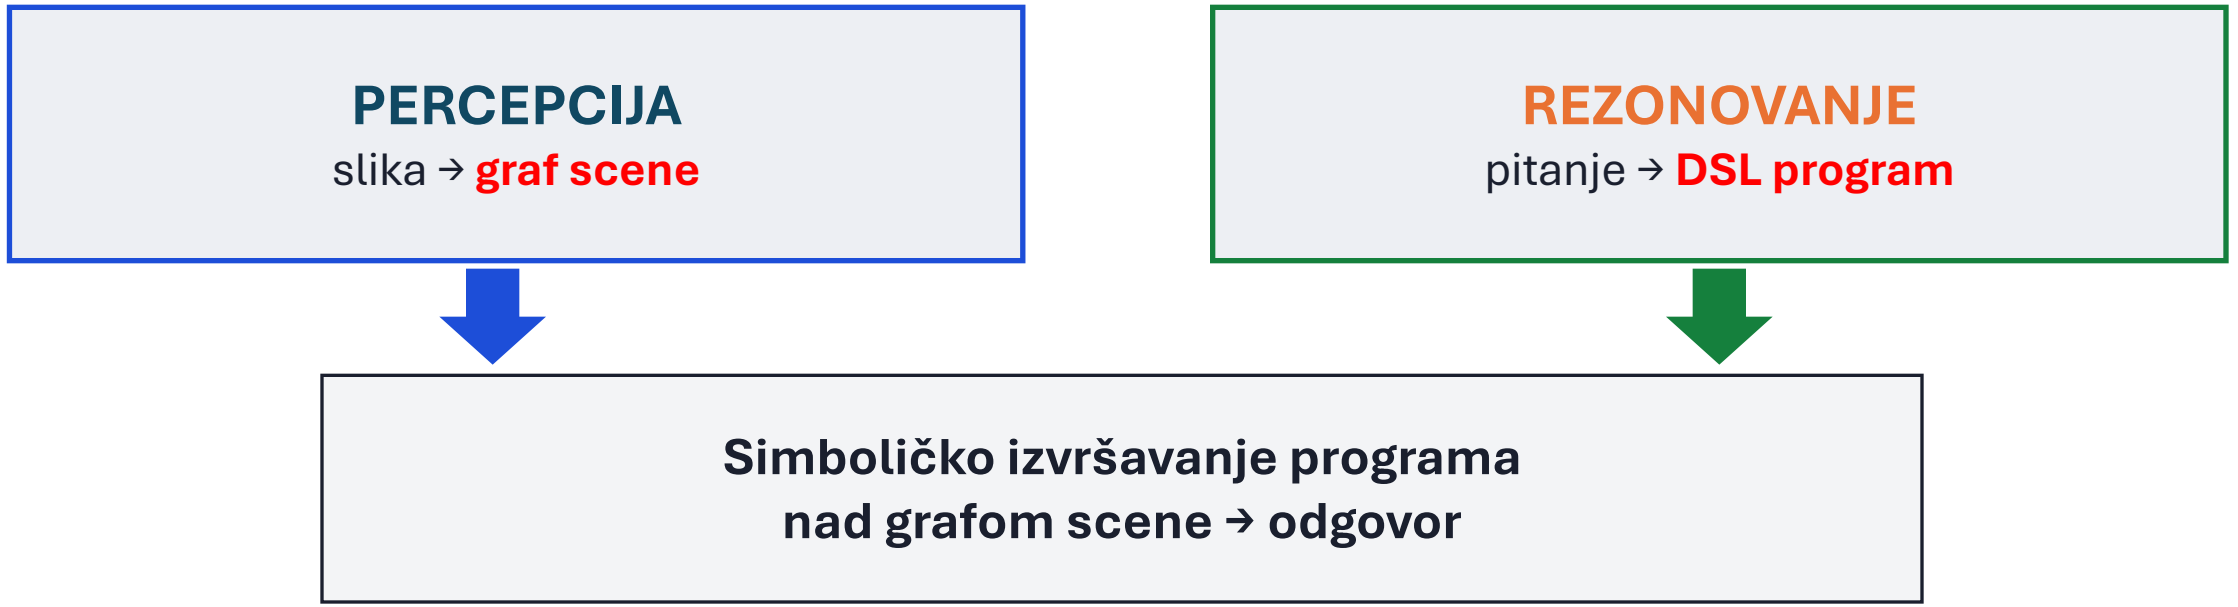
Problem: Vizuelno odgovaranje na pitanja (VQA)



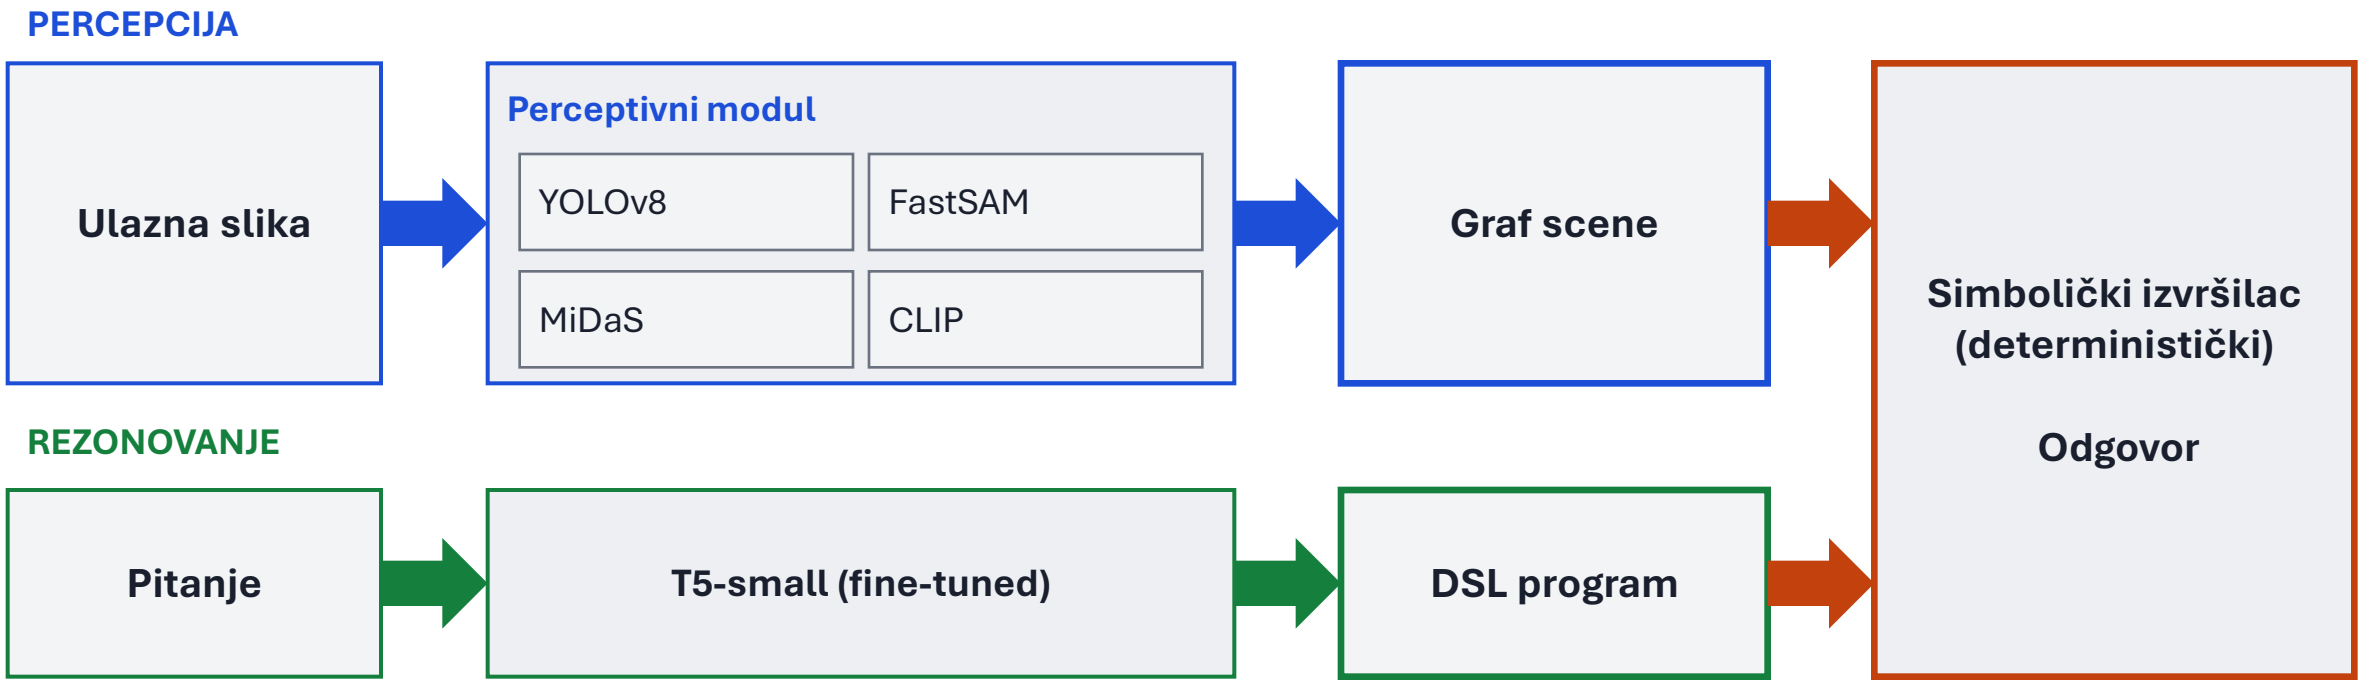
Pitanje: "How many cylinders are there in the image?" →
Odgovor: 3

- Ulaz: slika + pitanje na prirodnom jeziku → Izlaz: odgovor (broj / da-ne / atribut)
- Potpuno neuronski modeli: visoka tačnost, ali **crna kutija**
- **Problem: kada model pogreši - gde je nastala greška?**

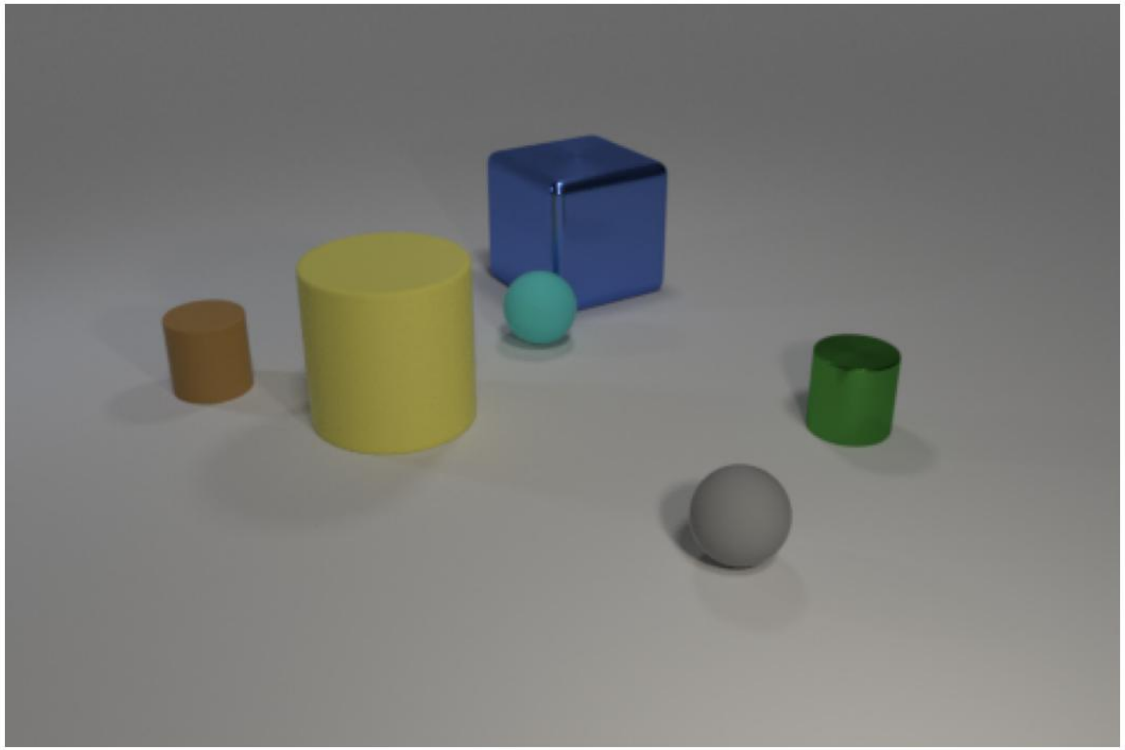
Rešenje: neurosimbolički pristup



Arhitektura sistema



Ulaz u sistem

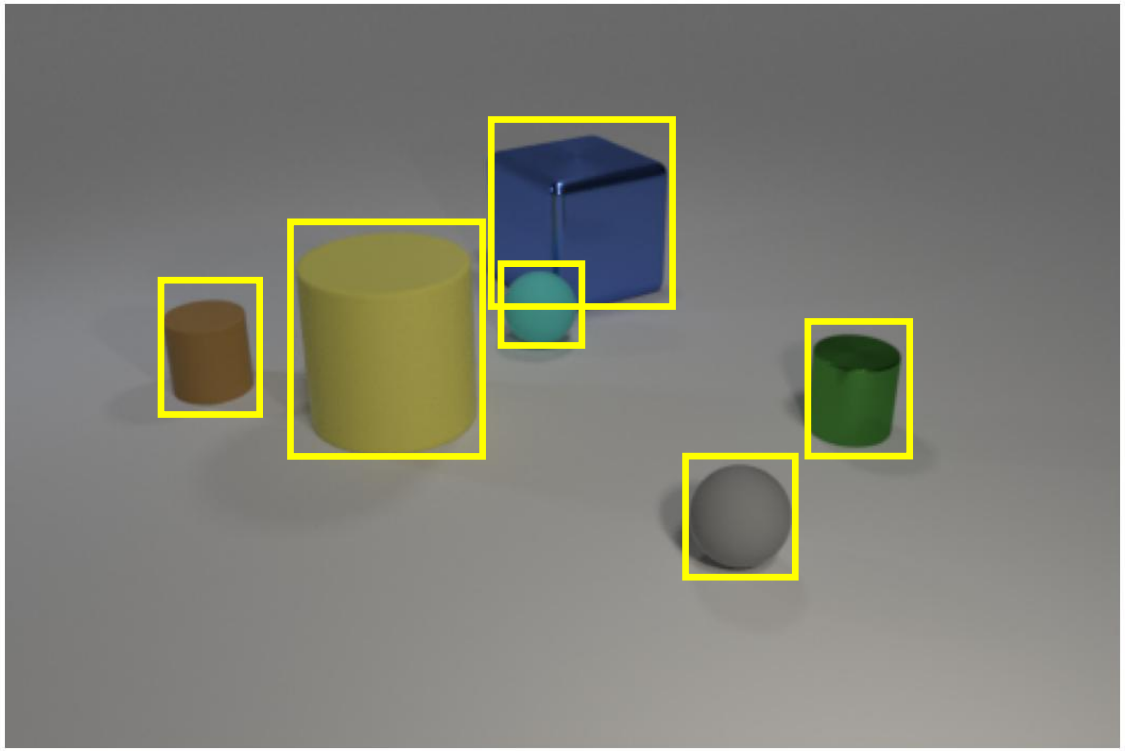


Pitanje: "What color is the cube behind the cyan sphere?"

Ulazna slika

Sistem dobija sliku scene i pitanje na prirodnom jeziku. Cilj je odgovor: broj, da/ne, ili vrednost atributa.

Detekcija objekata



Pitanje: "What color is the cube behind the cyan sphere?"

YOLOv8m x FastSAM

Hibridna detekcija

YOLOv8 pronalazi granične okvire svih šest objekata; FastSAM u režimu "segmentiraj sve" dopunjuje detekcije koje YOLO propusti. Rezultati se spajaju po IoU meri preklapanja.

Procena dubine



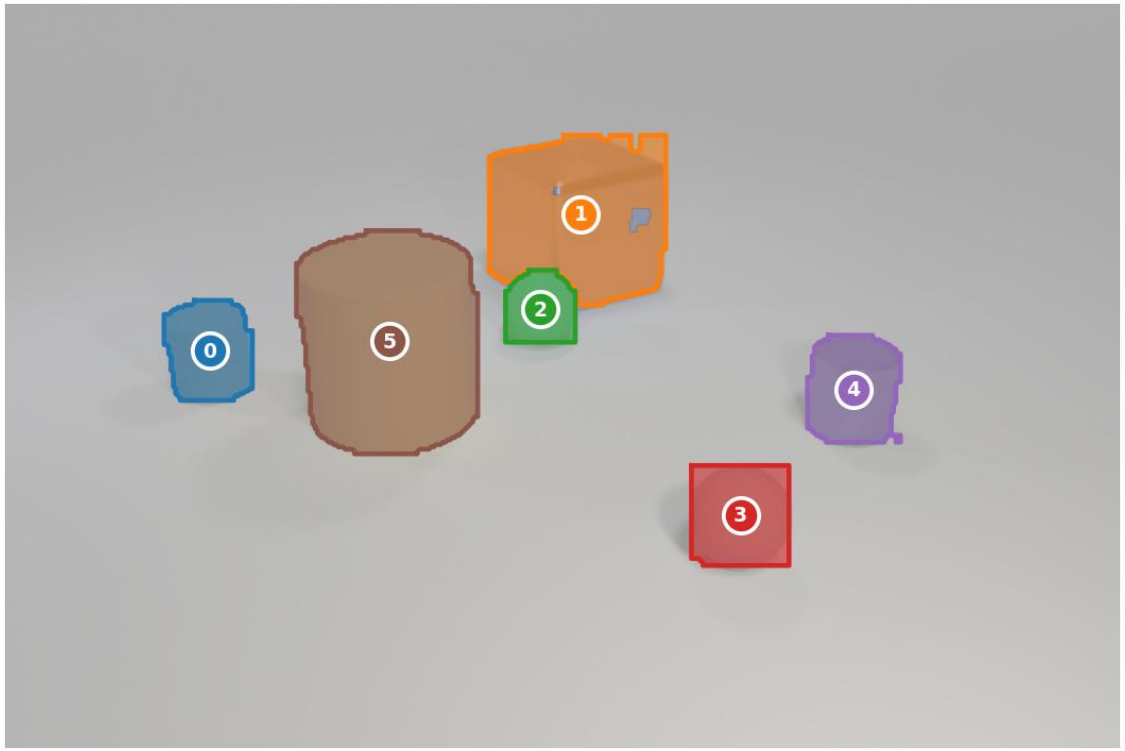
Pitanje: "What color is the cube behind the cyan sphere?"

MiDaS

Mapa relativne dubine

MiDaS iz jedne slike procenjuje relativnu dubinu: svetlije znači bliže. Dubina služi za relacije ispred/iza i za razrešavanje preklapanja maski u sledećem koraku.

Maske i Z-bafer



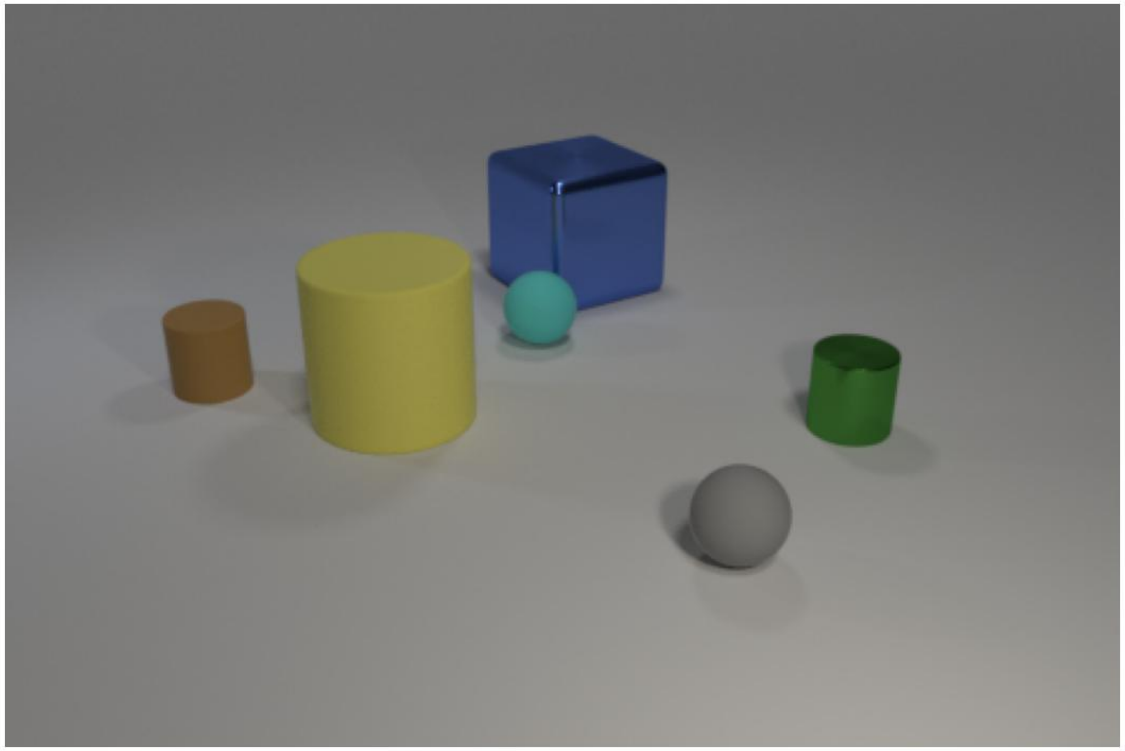
Pitanje: "What color is the cube behind the cyan sphere?"

FastSAM x Z-bafer

Segmentacija bez preklapanja

Za svaki okvir se izdvaja precizna maska. Z-bafer svaki piksel dodeljuje tačno jednom objektu.

Atributi → graf scene



Pitanje: "What color is the cube behind the cyan sphere?"

CLIP (zero-shot)

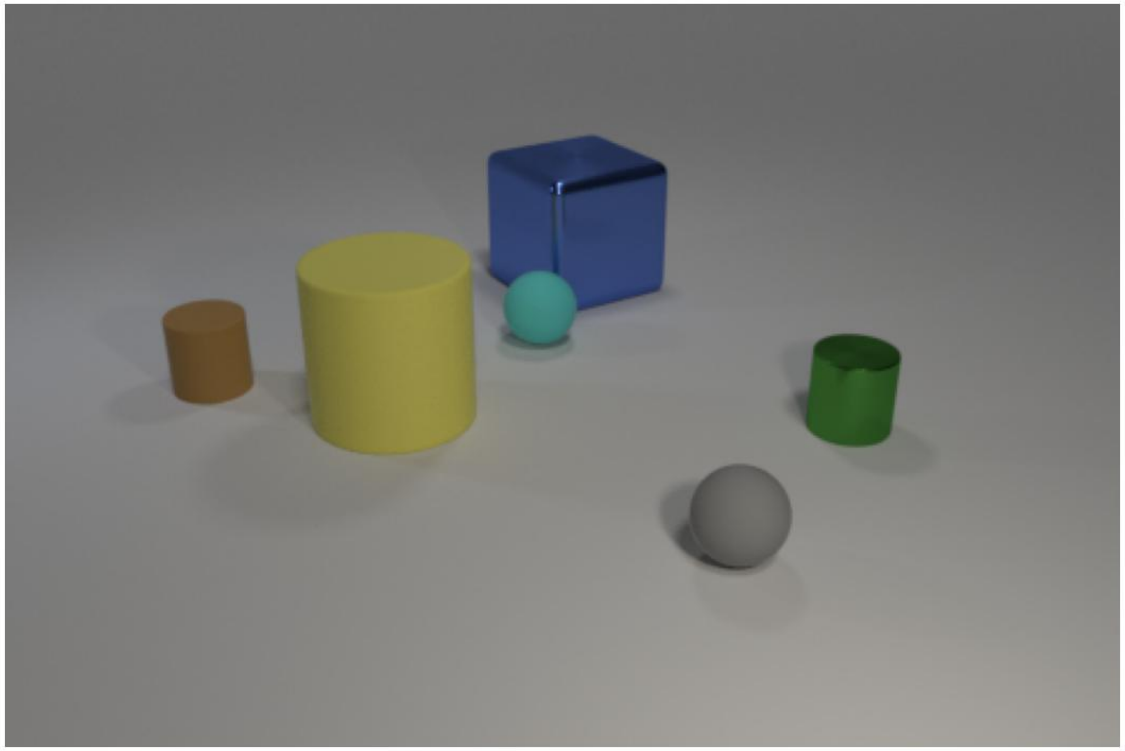
Atributi → graf scene

CLIP klasifikuje boju, oblik i materijal svakog objekta.

```
objects:
  0  brown   cylinder  rubber  S
  1  yellow  cylinder  rubber  L
  2  blue    cube      metal   L
  3  cyan    sphere    rubber  S
  4  green   cylinder  metal   S
  5  gray    sphere    rubber  S

relationships:
  behind[3] = [2] ← iza svetlo plave sfere
  left[2]   = [0, 1]
  right[3]  = [4, 5]
 …
```

Pitanje → DSL program



Pitanje: "What color is the cube behind the cyan sphere?"

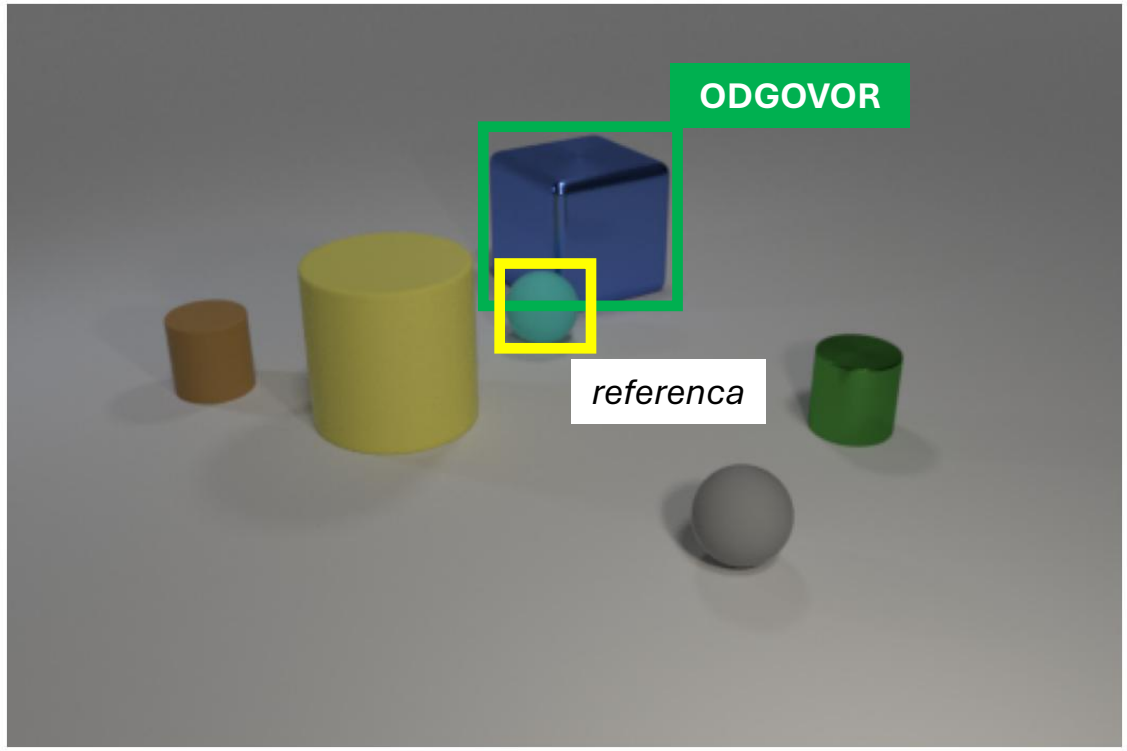
T5-small (fine-tuned)

Pitanje → DSL program

```
1  scene
2  filter_color[cyan]
3  filter_shape[sphere]
4  unique
5  relate[behind]
6  filter_shape[cube]
7  unique
8  query_color
```



Simboličko izvršavanje



Pitanje: "What color is the cube behind the cyan sphere?"

Executor - deterministički

Program se izvršava korak po korak

```
1  scene
2  filter_color[cyan]
3  filter_shape[sphere]
4  unique
5  relate[behind]
6  filter_shape[cube]
7  unique
8  query_color
```

Odgovor: „blue"

Eksperimentalna postavka

CLEVR
Sintetičke scene, šablonska pitanja - skup za obučavanje i osnovnu evaluaciju.

CLEVR-CoGenT
Nove kombinacije atributa koje se nisu javljale u treningu - testira kompozicionu generalizaciju.

CLEVR-Humans
Pitanja koja su formulisali ljudi na prirodnom jeziku, sa sinonimima.

Dva toka evaluacije

GT tok (referentni)
Referentni graf scene → Program → Odgovor
Izoluje se kvalitet rezonovanja

E2E tok (kompletan sistem)
Slika → Graf scene (izgrađen) → Program → Odgovor

Prevođenje pitanja u DSL (referentni tok)

Skup podataka	Tačnost	Validni programi	Greška izvršavanja
CLEVR (referentni)	**99,9%**	**100,0%**	**0,0%**
CLEVR-CoGenT valB	**99,7%**	**100,0%**	**0,1%**
CLEVR-Humans (pre RL)	**41,4%**	**90,5%**	**25,5%**
CLEVR-Humans (posle RL)	**57,1%**	**92,6%**	**0,6%**

REINFORCE (bez ijedne programske anotacije iz Humans domena)

Tačnost: 41,4% ——▶ **57,1%** (+15,7 pp)

Greška izvršavanja: **25,5%** ——▶ **0,6%** (−24,9 pp)

Direktna evaluacija percepcije: lokalizacija grešaka

Detekcija	Vrednost
Odziv	**97,5%**
Preciznost	**88,7%**
F1	**92,9%**
FN / slici	**0,16**
FP / slici	**0,80**

CLIP atributi	Tačnost
Oblik	**95,5%**
Materijal	**94,4%**
Veličina	**92,8%**
Boja	**87,8%**

Prostorne relacije	Tačnost
front	**68,6%**
right	**66,7%**
left	**66,5%**
behind	**44,3%**
Ukupno	**61,5%**

green	blue	red	yellow	gray	brown
97%	**91%**	**90%**	**87%**	**86%**	**71%**

Koliko košta percepcija?

Skup	GT tok	E2E tok	Razlika
CLEVR val	**99,9%**	**79,0%**	**−20,9**
CoGenT valB	**99,7%**	**79,0%**	**−20,7**
CLEVR-Humans (pre RL)	**41,4%**	**32,7%**	**−8,7**
CLEVR-Humans (posle RL)	**57,1%**	**45,6%**	**−11,5**

Provera dijagnoze - tipičan program filtrira po boji, obliku i materijalu:

P(sva 3 filtra tačna) ≈ 0,878 × 0,955 × 0,944 ≈ **79,2%**

Izmerena E2E tačnost: **79,0%** ✓

Poređenje sa IEP i NS-VQA

Skup	IEP	NS-VQA	Predloženi - E2E	Predloženi - GT
CLEVR val	96,9%	99,8%	79,0%	**99,9%**
CoGenT B	73,7%	**63,9%**	**79,0%**	**99,7%**
CLEVR-Humans	66,6%	67,0%	45,6%	**57,1%**

GT tok = nivo najboljih neurosimboličkih sistema (99,9% vs NS-VQA 99,8%)

Na CoGenT-u E2E nadmašuje oba rada - odvojeni atributi u DSL-u ≠ naučene korelacije (NS-VQA: 48 zajedničkih klasa → pad na 63,9%)

Zaključak i budući rad

Tri glavna zaključka

- Neurosimbolički pristup: rezonovanje **~99,9%** kada je graf scene tačan
- Glavna vrednost: **greške se lokalizuju po fazama** (identifikovano: boja i prostorne relacije)
- RL omogućava adaptaciju na prirodan jezik **bez anotacija** (+15,7 pp)

Budući rad

- Specijalizovani klasifikator boja
- Bolja procena dubine za prostorne relacije
- Proširenje DSL-a (superlativi, „between", najčešći atribut)

Hvala na pažnji

Pitanja?